机器人论文速读 | π0.5：面向开放世界泛化的 VLA 模型

Physical Intelligence · arXiv · 2025.04

VLA　Open-world Generalization　Co-training　多源数据

1. 一句话总结

$\pi_{0.5}$ 通过多源异构数据协同训练，将其他机器人经验、网络语义信息、语言指令与高层子任务监督整合进统一的视觉-语言-动作模型，使机器人能够在陌生家庭环境中完成长时程、多步骤的清洁与整理任务。

2. 研究动机

1. 现有 VLA 在真实世界中的开放世界泛化能力仍然不足。
2. 仅靠扩大单一机器人数据规模，难以覆盖多样化家庭场景。
3. 机器人需要从多来源知识中迁移经验，才能实现更强泛化。

3. 核心亮点

01 多源数据协同训练
融合其他机器人数据、网络数据、语言指令和高层语义监督。

02 两阶段训练
先预训练建立通用能力，再后训练适配移动机械臂操作。

03 分层推理
先预测高层子任务，再生成低层动作。

04 开放世界泛化
可在从未见过的新家中执行厨房清洁、卧室整理等多步骤任务。

模型总览 / 多源数据来源（Fig. 1）



4. 厨房清洁任务示例（Fig. 2）



① 关闭柜门　② 打开抽屉　③ 放入物品　④ 擦拭台面　⑤ 放入水槽　⑥ 放好餐具

在一个从未见过的新厨房中，完成长时程（10–15 分钟）多步骤清洁任务！

5. 这篇论文最重要的一句话

真正的机器人泛化，
不只是更多机器人数据，
而是多源知识迁移。

小提示

首次展示：端到端学习型机器人可在全新家庭中完成 10–15 分钟的长时程清洁与整理任务。

突破！

论文信息

- 作者：Physical Intelligence
- 时间：2025.04
- 来源：arXiv
- 模型：$\pi_{0.5}$（VLA）

#机器人学　#VLA　#具身智能　#论文笔记　#开放世界泛化

方法拆解 | $\pi_{0.5}$ 如何实现开放世界泛化？

多源数据 + 两阶段训练 + 分层推理 + Action Expert

VLA | Co-training | Hierarchical Inference | Flow Matching

1. 多源数据配方：汇聚多模态、多来源的监督信号

机器人数据



来自不同平台与
不同环境的操作轨迹

网络数据



Q：图中有几张桌子？
A：2 张

Q：检测到哪些物体？
A：杯、碗、瓶…

图文、问答、检测
网页语义信息等

语言指令

“把衣服放进洗衣机”
“清理桌面上的杂物”
“整理床铺并叠被子”

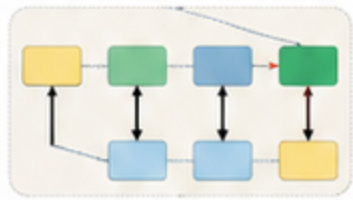
自然语言任务描述
与约束条件

目标检测



物体与场景
感知监督

语义子任务预测



高层动作序列
与子任务监督

核心思想：把异构知识映射到统一的视觉–语言–动作框架中。

2. 两阶段训练：先通用，再专精

阶段一：预训练（Pre-training）

- 在异构任务混合数据上训练
- 机器人动作离散化为 FAST tokens
- 目标：建立通用的视觉–语言–动作表示

大规模多模态数据

机器人数据 + 网络数据 + 语言指令

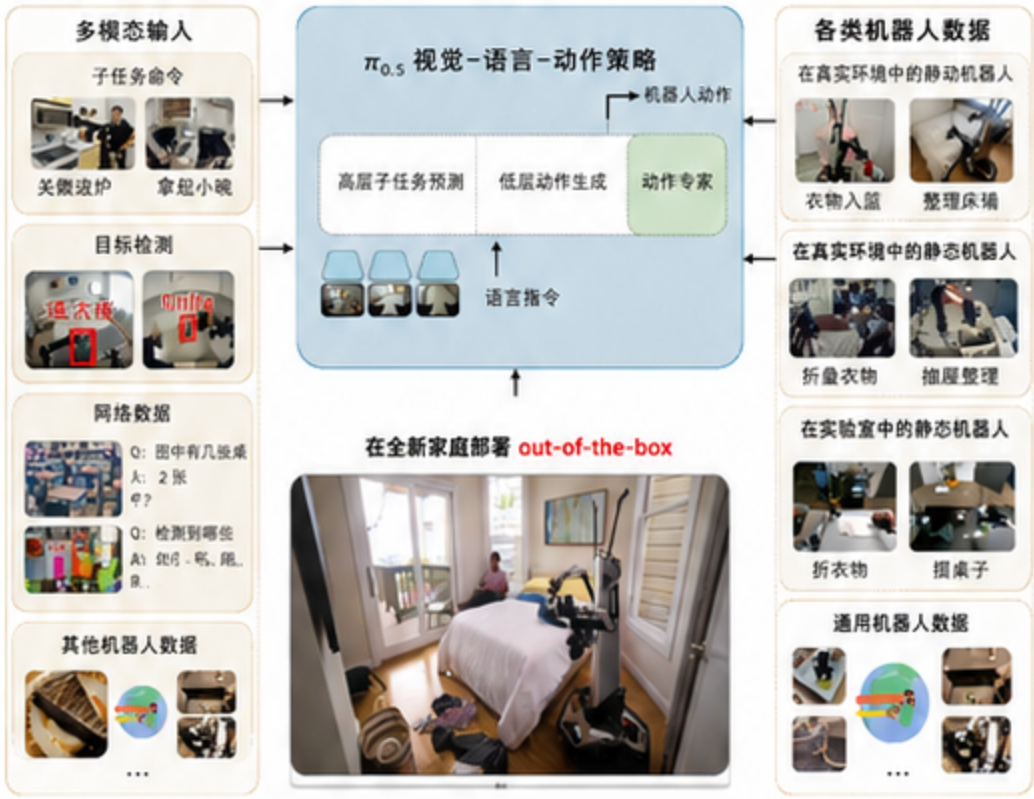
→ VLA Backbone（离散动作建模） … FAST tokens

阶段二：后训练（Post-training）

- 专门面向移动机械臂任务
- 引入 Action Expert
- 用 Flow Matching 生成连续动作块
- 目标：获得更细粒度、更实时的控制能力

VLA Backbone（初始化）
↓
Action Expert
↓
Flow Matching
↓
连续动作块（连续控制） …

方法结构总览（源自论文 Fig.1）



3. 推理流程：分层规划，逐步执行

输入图像 + 指令
来自新环境的图像
与自然语言指令

→ **高层子任务预测**
预测下一步要做什么
（子任务序列）

→ **低层动作生成**
生成连续动作块
（精细执行）

→ **执行长时程任务**
在全新家庭环境中
完成多步骤任务

分层设计的关键要点：

1. 高层推理负责决定“下一步做什么”
2. 低层动作负责决定“具体怎么做”
3. 这种分层设计更适合多步骤家庭任务

4. 为什么这种方法有效？

低层动作可以从其他机器人动作数据中学习控制经验
大量真实操作轨迹 → 提升低层控制的泛化性与鲁棒性

高层策略可以从网络语义、语言指令和子任务监督中学习常识与任务结构
丰富的语义知识 → 更懂任务，更会规划

训练时离散、推理时连续，兼顾训练效率与执行精度
离散 token 扩展规模，连续动作提升控制质量

5. 任务示例：在全新厨房完成“清洁厨房”任务（源自论文 Fig.2）



① 关闭柜门 ② 打开抽屉 ③ 放入物品 ④ 擦拭台面 ⑤ 放入水槽 ⑥ 放好餐具 …

关键设计一句话：

训练时用离散 token 扩展规模，
执行时用连续动作提升控制质量。

#机器人学 #VLA #具身智能 #论文笔记 #开放世界泛化

实验结果 | 泛化能力如何被验证？

评测环境、关键曲线与核心结论

VLA | Open-world Generalization | Co-training | 多源数据

① 评测设置

- 评测在训练中未出现的新厨房、新卧室与真实家庭中进行
- 同时包含可控的 mock 环境与更真实的 real homes
- 代表任务包括：


dishes in sink（放入水槽）


items in drawer（放入抽屉）

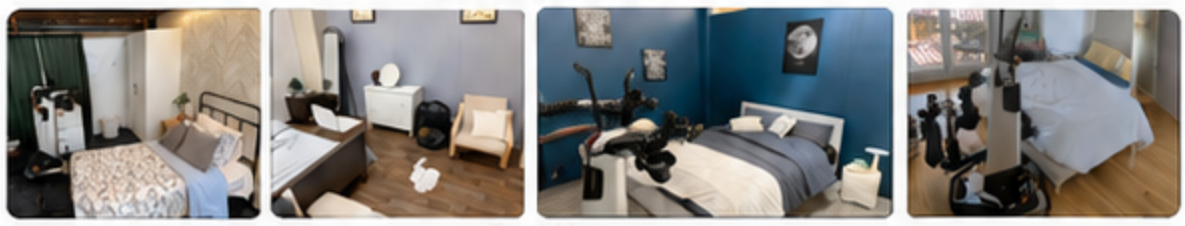

laundry basket（衣物入篮）


make bed（整理床铺）

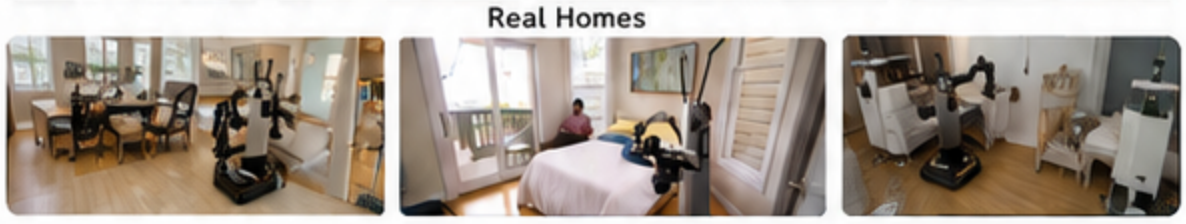
新环境（训练中未见过）Mock Kitchens



Mock Bedrooms



Real Homes

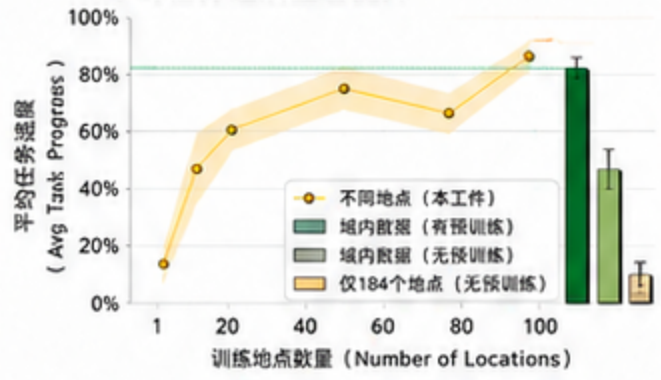


数据规模

论文使用约 **400 小时** 移动机械臂数据，并结合更多其他机器人与网络数据共同训练。

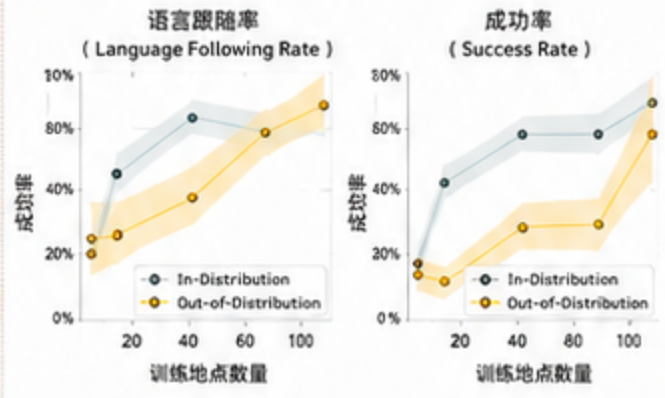
② 关键结果 1：更多环境，带来更强泛化

① 随训练地点数增加，平均任务进展显著提升



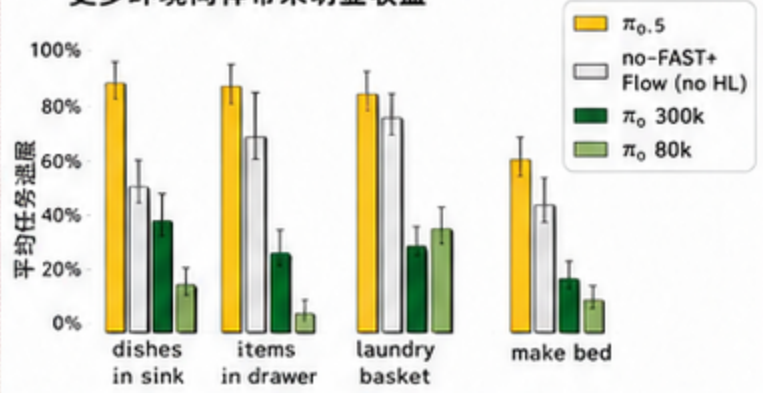
在 100 个地点训练时，平均进展达 ~85%+

② 语言跟随率和成功率也随之提升



随地点数增加，In-Distribution 与 OOD 两个维度均持续上升

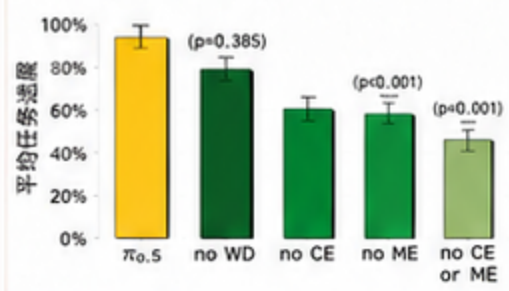
③ 对训练中未见过的物体类别（OOD），更多环境同样带来明显收益



在四个 OOD 任务上，更多环境带来显著提升

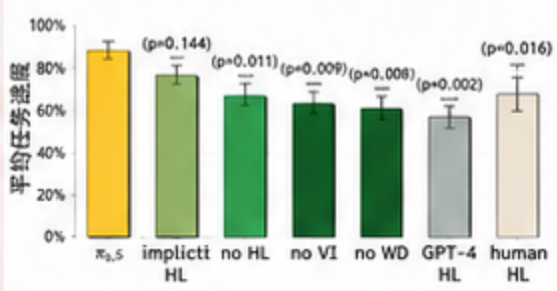
③ 关键结果 2：co-training 配方真的关键

① 移除跨机器人 / 跨环境数据会明显降低性能



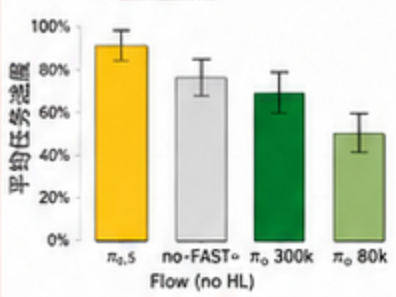
结论 跨机器人（ME）和跨环境（CE）贡献显著，缺一不可。

② web data 对语言跟随与新物体泛化尤其重要



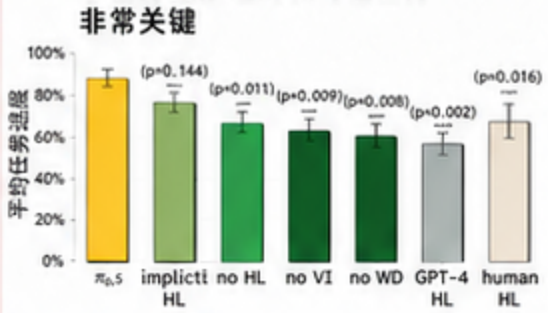
结论 去掉 web data（WD），性能显著下降。

③ $\pi_{0.5}$ 显著优于 π_0 和 π_0 FAST+Flow



结论 $\pi_{0.5}$ 在四个任务上全面领先，泛化优势明显。

④ 高层推理版本表现最好，说明子任务级推理对长时程任务非常关键



结论 显式/隐式高层推理（HL）带来稳定且显著收益。

④ 一句话实验结论

$\pi_{0.5}$ 的强泛化，不是因为见过测试环境，
而是因为多源协同训练带来了有效知识迁移。

⑤ takeaways 关键启示

数据多样性比单纯数据规模更重要
覆盖更多机器人、更多场景、更多来源，比单一来源的堆量更能提升泛化。

语言泛化和控制泛化可以同时提升
更多环境与 web 数据让模型在“理解指令 + 执行动作”上共同进步。

高层语义推理是长时程家务任务的重要支撑
显式或隐式的子任务级推理，让模型更稳、更会规划。

#机器人学 #VLA #具身智能 #论文笔记 #开放世界泛化

论文价值、局限与启发

从 π0.5 看通用机器人泛化的下一步

Physical Intelligence · arXiv · 2025.04

VLA | Open-world Generalization | Co-training | 多源数据

1. 这篇论文的 3 个核心贡献

01

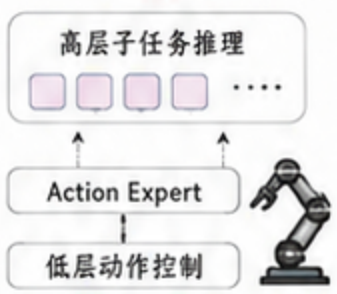


首次展示端到端学习型机器人在全新家庭中完成长时程、多步骤清洁与整理任务

02



03



用“高层子任务推理 + Action Expert”连接语义理解与细粒度动作控制

任务执行示例（多步骤可视化）

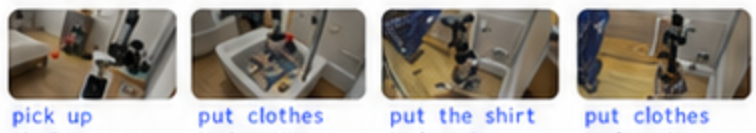
任务 1：把衣物放进抽屉



任务 2：整理水槽区域



任务 3：洗衣流程



从感知 → 规划 → 执行，长时程任务被逐步完成！

2. 论文仍有哪些局限？

01 

在抽屉、柜门、复杂空间交互等场景中仍会犯错

02 

对更复杂 prompt、长时记忆与更强任务规划能力的支持仍有限

03 

对大规模异构数据和训练资源依赖较高，工程成本不低

3. 我的启发 / 值得借鉴的研究思路

- 通用机器人不能只依赖单一平台的演示数据，而需要多源知识迁移。
- 高层语义监督对长时程、多步骤任务尤其关键。
- 面向未来 VLA / 持续学习研究，可以继续探索多源迁移、分层技能和开放世界评测。



持续探索 无限可能！

4. 一句话带走

开放世界泛化 = 多源知识迁移 + 分层推理 + 可执行的低层控制

5. 适合谁读？



对 VLA、具身智能、机器人泛化感兴趣的同学

建立系统认知与框架视角



想了解多源协同训练和长时程任务建模的研究者

获取方法细节与实证启发



关注真实世界机器人落地能力的人

理解技术到产品的关键路径

#机器人学 #VLA #开放世界泛化 #具身智能 #论文阅读

如果你做机器人泛化，这篇值得细读。